

华东理工大学2024-2025学年第2学期

《大数据与金融计算》实验报告

实验名称 中国股市FF三因子资产定价模型的实证检验

专 业	计金	姓名	高林锐	学号	22011854	班级	计金220
实验时间	2025.3.20		实验地点	信息楼319	指导教师	蒋志强	

实验目的/要求

- 1、掌握三因子模型参数估计方法和时间序列检验方法（单资产和多资产）
- 2、掌握三因子模型的横截面检验方法（排序法和Fama-Macbeth回归）

实验内容

- 1.认真阅读三篇文献资料（自己也可以下载相关文献进行阅读），了解资产定价模型的相关研究，重点关注其中的研究思路和方法。
- 2.任意选取七个行业指数，从锐思数据库或tushare数据库，下载这些指数的周度数据和三因子的周度数据，估计FF三因子模型参数，并逐个行业检验其是否满足FF三因子模型；再对七个行业进行FF三因子模型的多资产检验。（月度数据不少10年，周度数据不少于5年）
- 3.从锐思数据库或tushare数据库，提取中国股市2004-2023年所有股票的月收益率，月流通市值数据，月市盈率数据，观察和研究课本P52页表格3-6的计算方法，计算先按市值再按盈利价格比（市盈率倒数）序贯排序的资产组合月平均收益率（注意：变量排序分成5组，不需要分成10组），并对结果进行讨论。
- 4.从锐思数据库或tushare数据库，提取中国股市2004-2023年，所有股票的月收益率，月流通市值数据，月市盈率数据，月CAPM风险因子Beta数据，请利用Fama-MacBech回归检验市值、盈利价格比（市盈率倒数）、CAPM风险因子Beta对收益率的解释性。

实验总结

请提供对本次实验结果的讨论分析，以及实验的心得和体会。包括对知识点的掌握，算法的理解，以及对理论课程和实验课程改进的建议。（不少于500字）

本次实验通过对Fama-French三因子模型的系统性实证检验，使我对资产定价理论有了更深入的理解。我对中国股市2009-2017年的行业指数数据和2004-2023年的个股数据进行了多维度分析，揭示了中国市场的独特定价特征。

实验结果呈现了两个层面的有趣发现。在行业指数层面，FF三因子模型展现出良好的解释能力，所有行业的截距项（ α ）均不显著异于零，且调整R方介于0.63至0.72之间。行业风险暴露存在显著异质性：银行业表现出低市场风险、负规模敏感性和正价值敏感性，而电气设备等行业则呈现高市场风险、正规规模敏感性和负价值敏感性。这种差异反映了行业特性对风险因子敏感度的影响。

然而，在个股层面的分析中，我发现了与经典理论相悖的现象。序贯排序分析揭示中国股市存在显著的反向规模效应和反向价值效应：大市值股票收益率系统性高于小市值股票，低盈利价格比（高市盈率）的成长型股票表现优于高盈利价格比的价值型股票。Fama-MacBeth回归进一步确认了这一发现，对数流通市值系数显著为正，盈利价格比系数显著为负。这与美国市场截然不同，反映了中国股市的独特结构和投资者行为特征。

这些差异可能源于中国特有的市场环境：IPO审核制度对小市值公司形成壁垒，机构投资者偏好流动性较好的大市值股票，以及投资者对成长性的系统性乐观预期。这些因素共同导致了传统因子效应在中国市场表现出"反转"现象。

通过本次实验，我掌握了资产定价模型的理论框架和实证检验方法。特别是对单资产检验与多资产联合检验的区别、序贯排序法与Fama-MacBeth回归的应用有了更深刻的认识。在算法层面，我理解了GRS检验的统计原理，学会了处理金融时间序列数

据中的异常值和缺失值，以及如何正确实现二维排序和两阶段回归。

教师批阅：

实验成绩：

教师签名：

日期：

中国股市 FF 三因子资产定价模型的实证检验

计金 220 22011854 高赫铠

摘要: 本文基于 2009-2017 年中国 A 股市场七个行业指数及 2004-2023 的个股数据, 对 Fama-French 三因子资产定价模型进行系统性实证检验, 旨在探究该模型在中国市场的适用性及中国股市的独特定价特征。研究结果表明, 从行业指数角度看, 单资产时间序列检验与 GRS 联合检验均显示三因子模型能够较好地解释行业指数的超额收益, 行业间风险暴露存在显著异质性, 如银行业表现出低市场风险、负规模敏感性和正价值敏感性, 而电气设备、化工等行业则呈现高市场风险、正规规模敏感性和负价值敏感性。然而, 在个股层面, 序贯排序分析揭示出中国股市存在显著的反向规模效应和反向价值效应, 即大市值股票收益率高于小市值股票, 成长型股票表现优于价值型股票, 这与经典 Fama-French 模型的结论相反。Fama-MacBeth 横截面回归分析进一步证实了上述发现, 对数流通市值系数显著为正, 盈利价格比系数显著为负, 表明市值和盈利价格比对股票收益率具有显著解释力。此外, CAPM 中的 Beta 系数虽整体显著为正, 但其显著性在近期有所减弱。研究结果表明, 中国股市的资产定价机制具有独特性, 传统基于美国市场的多因子模型在中国市场存在局限性, 需发展本土化资产定价模型, 同时为投资者提供了在中国市场配置大市值成长型股票的理论依据。

1 文献综述

金融资产定价理论是现代金融经济学的重要组成部分, 其中资本资产定价模型 (CAPM) 作为资产定价理论的重要基石之一, 受到了广泛的关注与深入的研究。Fama 和 French 在 1993 年提出的三因子模型进一步拓展了 CAPM 模型, 引入了规模因子 (SMB) 和账面市值比因子 (HML), 以更好地解释股票收益率的横截面差异。然而, 随着资本市场的不断发展, 该模型的适用性在不同市场中受到质疑, 尤其是在新兴市场中。近年来, Fama 和 French 在 2015 年提出的五因子模型进一步引入了盈利能力因子 (RMW) 和投资风格因子 (CMA), 以期更全面地解释股票收益率的差异。

在中国市场, 张宏亮^[1]对 2001-2011 年沪深两市的数据进行了实证检验, 发现规模、账面市值比、市盈率倒数与股票收益率呈负相关, 而贝塔系数和财务杠杆与收益率呈正相关。这一研究结果表明, 传统的 CAPM 模型在中国市场中存在局限性, 而三因子模型在中国市场中具有一定的适用性。然而, 赵胜民^[2]对 2003-2014 年中国 A 股市场的数据进行分析后发现, Fama-French 五因子模型中的 RMW 和 CMA 因子在中国市场中并不显著, 而三因子模型的解释能力更强。这表明在中国市场中, 盈利能力因子和投资风格因子可能并不像在美国市场中那样重要。

进一步地, 李志兵^[3]对 1994-2015 年中国 A 股市场的数据进行了分析, 发现股权分置改革前后, 五因子模型的适用性存在显著差异。股改前, 市场风险占据主导地位, 盈

利能力、投资风格及动量因子“冗余”；股改后，这些因子的风险溢价显著，且存在经五因子模型调整后仍然显著的反转效应。这一研究表明，随着中国资本市场的制度变革，资产定价模型的适用性也会发生变化。

在国际比较方面，Carpenter^[4]研究了中国股票市场的价格信息含量和资本配置效率，发现自 2004 年以来，中国股票价格对未来的利润预测能力与美国相当，且这种信息含量对私人企业的投资效率提升有显著作用。然而，对于国有企业，尤其是在 2008 年金融危机后的刺激政策期间，价格信息含量和投资效率均有所下降。这一研究结果表明，中国股票市场在信息传递和资本配置方面具有一定的价值，但不同所有制企业的表现存在差异。

此外，Liu^[5]对中国股票市场的规模效应和价值效应进行了深入研究，发现中国市场的规模效应和价值效应显著，且使用收益-价格比（EP）构建的价值因子比账面市值比（BM）更能捕捉中国市场的价值效应。他们还发现，排除潜在的壳价值干扰后，规模和价值因子在中国市场的表现优于传统的 Fama-French 三因子模型。这一研究结果进一步证实了中国股票市场在资产定价方面的独特性。

综合上述研究可以发现，中国股票市场在资产定价方面具有其独特性，传统的 CAPM 模型和 Fama-French 三因子模型在中国市场的适用性受到一定限制。随着中国资本市场的不断发展和完善，资产定价模型需要考虑更多的市场特征和投资者行为因素。因此，深入研究中国股票市场的收益率分布特征和影响因素，对于理论探索和实践投资策略的制定都具有重要意义。

2 数据与方法

2.1 数据描述

本研究使用中国 A 股市场 2009 年至 2017 年的数据，从锐思数据库和 Tushare 数据库获取七个行业指数的周度数据以及中国股市的月度数据。选取的七个申万行业指数包括：银行（801780.SI）、化工（801030.SI）、钢铁（801040.SI）、有色金属（801050.SI）、建筑材料（801710.SI）、电气设备（801730.SI）和医药生物（801150.SI）。此外，我们还获取了三因子模型所需的月度因子数据。

对于横截面检验，我们收集了 2004-2023 年所有 A 股股票的月度收益率、流通市值数据、市盈率数据以及 CAPM 风险因子 Beta 数据。市场组合收益率使用沪深 300 指数（000300.SH）的周度和月度收益率作为代理，无风险利率则采用中国人民银行公布的相应期限国债收益率。

数据预处理包括异常值处理、缺失值填补和变量计算。特别地，我们计算了盈利价格比（市盈率的倒数）作为价值因子的衡量指标，并对流通市值取对数以减小其尺度影响。所有变量均进行了 1% 和 99% 分位数的缩尾处理，以减轻极端值对分析结果的影响。

2.2 Fama-French 三因子模型检验方法

2.2.1 单资产时间序列检验

对每个行业指数，我们首先进行 FF 三因子模型的时间序列回归，模型设定如下：

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_i(R_{m,t} - R_{f,t}) + s_i\text{SMB}_t + h_i\text{HML}_t + \varepsilon_{i,t} \quad (2-1)$$

其中， $R_{i,t}$ 为行业 i 在时间 t 的收益率， $R_{f,t}$ 为无风险收益率， $R_{m,t}$ 为市场收益率， SMB_t 和 HML_t 分别为规模因子和价值因子。 α_i 、 β_i 、 s_i 和 h_i 为待估计参数， $\varepsilon_{i,t}$ 为随机扰动项。

计算三因子时，我们按照 Fama-French (1993) 的方法，先按市值将股票分为大小两组，再按账面市值比（使用市盈率倒数作为代理变量）将股票分为高、中、低三组，形成六个投资组合。SMB 因子为小市值三个组合的平均收益率减去大市值三个组合的平均收益率；HML 因子为高账面市值比两个组合的平均收益率减去低账面市值比两个组合的平均收益率。

对每个行业，我们估计上述模型并检验 α_i 是否显著不为零。如果 α_i 不显著，且模型的整体 F 检验显著，则认为该行业满足 FF 三因子模型。

2.2.2 多资产联合检验

为验证 FF 三因子模型对所有七个行业的解释能力，我们采用 Gibbons-Ross-Shanken (GRS) 检验方法进行多资产联合检验。GRS 统计量计算如下：

$$\text{GRS} = \left(\frac{T - N - K}{N} \right) \left(1 + \hat{\mu}' \hat{\Omega}^{-1} \hat{\mu} \right)^{-1} \hat{\alpha}' \hat{\Sigma}^{-1} \hat{\alpha} \quad (2-2)$$

其中， T 为样本容量， N 为资产数量， K 为因子数量， $\hat{\mu}$ 为因子均值向量， $\hat{\Omega}$ 为因子协方差矩阵， $\hat{\alpha}$ 为截距项向量， $\hat{\Sigma}$ 为残差协方差矩阵。

GRS 检验的原假设为所有行业的 α_i 同时为零。在显著性水平为 5% 下，如果无法拒绝原假设，则表明 FF 三因子模型能够很好地解释这些行业的超额收益率。

2.3 序贯排序法检验

本研究采用 Fama-French (1992) 中提出的序贯排序方法，研究市值和盈利价格比对股票收益率的联合影响。序贯排序法是资产定价研究中常用的非参数检验方法，能直观展示不同特征组合的收益率差异。

在实证过程中，我们对每个月的股票数据首先按照流通市值大小进行排序，将样本均分为 5 个投资组合，从最小市值组合到最大市值组合。随后，在每个市值分组内，再按照盈利价格比（市盈率的倒数）从高到低进行排序，进一步将每个市值组分为 5 个子组合，形成高盈利价格比（价值型）到低盈利价格比（成长型）的谱系。通过这种二维排序，我们构建了共计 25 个投资组合。

对于每个投资组合，我们计算其月平均收益率，并对研究期间（2004-2023 年）的数据取时间序列平均值，最终形成 5×5 的排序结果表格。此表格的行代表不同市值分组，列代表不同盈利价格比分组，单元格数值则表示相应投资组合的平均月收益率。

通过分析结果表格中的收益率模式，特别是行方向和列方向的边际收益率差异，我们可以识别中国 A 股市场中市值效应和价值效应的存在性及其相互作用关系。例如，如果最小市值组合的平均收益率显著高于最大市值组合，则表明存在显著的小市值效应；同样，如果高盈利价格比组合的平均收益率显著高于低盈利价格比组合，则表明存在显著的价值效应。

2.4 Fama-MacBeth 回归检验

本研究采用 Fama-MacBeth (1973) 两阶段回归方法检验市值、盈利价格比和 CAPM Beta 对股票收益率的解释能力。Fama-MacBeth 回归首先考察每个月份的横截面关系，随后对时间序列上的系数进行统计推断，该方法能有效处理截面相关性问题的，在资产定价实证研究中被广泛应用。

在方法的第一阶段，我们对每个月份 t 的横截面数据进行 OLS 回归。回归模型设定如下：

$$R_{i,t} = \gamma_{0,t} + \gamma_{1,t}\beta_i + \gamma_{2,t}\ln(\text{ME}_{i,t}) + \gamma_{3,t}\text{E/P}_{i,t} + \epsilon_{i,t} \quad (2-3)$$

其中， $R_{i,t}$ 表示股票 i 在月份 t 的收益率， β_i 代表股票 i 的 CAPM Beta 值， $\ln(\text{ME}_{i,t})$ 为对数流通市值， $\text{E/P}_{i,t}$ 为盈利价格比。通过回归，我们获得了每个月份的横截面系数估计值 $\gamma_{k,t}$ 。

方法的第二阶段则着眼于对上述系数的时间序列进行统计分析。我们计算各系数在时间维度上的平均值：

$$\bar{\gamma}_k = \frac{1}{T} \sum_{t=1}^T \gamma_{k,t} \quad (2-4)$$

随后，我们通过计算 t 统计量评估各系数的统计显著性：

$$t(\bar{\gamma}_k) = \frac{\bar{\gamma}_k}{\sigma(\gamma_{k,t})/\sqrt{T}} \quad (2-5)$$

其中， $\bar{\gamma}_k$ 为第 k 个系数的时间序列平均值， $\sigma(\gamma_{k,t})$ 为其标准差， T 为样本中包含的月份数量。

我们不仅对整个样本期间（2004-2023 年）进行分析，还将其划分为两个子期间（2004-2013 年和 2014-2023 年）进行比较，以检验各因素效应的稳健性和时变特性。

2.5 模型评估与稳健性分析

我们通过多种指标评估模型拟合效果。对时间序列回归，主要考察调整后的 R^2 和 F 统计量；对 Fama-MacBeth 回归，则关注各系数的时间序列平均显著性及其在不同子期间的稳定性。

为增强结果稳健性，我们对各变量进行了 1% 和 99% 分位数缩尾处理，并剔除了市盈率为负或极端的观测值。在计算 Beta 值时，我们采用了 36 个月的滚动窗口方法，对于数据不足的情况则使用全样本估计，同时对异常 Beta 值进行了修正处理。

所有分析均使用 Python 实现，回归分析采用 statsmodels 库，数据处理和可视化分别使用 pandas、numpy 和 matplotlib 等工具包。

3 实证结果

3.1 FF 三因子模型的单资产时间序列检验

本研究基于 2009 至 2017 年的周度数据对七个行业指数进行了系统性分析，首先通过单资产时间序列回归方法，评估 Fama-French 三因子模型对各行业指数超额收益率的解释能力。表 3.1 呈现了各行业的三因子模型估计结果。

表 3.1 各行业 FF 三因子模型回归结果

行业	α	β_{MKT}	β_{SMB}	β_{HML}	R^2
银行	-0.0010 (-0.9180)	0.8810*** (27.8214)	-0.2508*** (-4.1067)	0.2868*** (5.7946)	0.674
化工	-0.0021 (-1.6336)	1.0339*** (26.3125)	0.9800*** (12.9317)	-0.4834*** (-7.8723)	0.694
钢铁	-0.0020 (-1.6048)	1.0681*** (27.7815)	0.6041*** (8.1471)	0.0887 (1.4766)	0.662
有色金属	-0.0014 (-1.0516)	1.1537*** (28.4639)	0.8392*** (10.7356)	-0.3241*** (-5.1158)	0.695
建筑材料	-0.0018 (-1.4872)	1.0779*** (30.0962)	0.8362*** (12.1048)	-0.3708*** (-6.6246)	0.725
电气设备	-0.0021 (-1.3027)	1.1287*** (23.2700)	1.0310*** (11.0212)	-0.5391*** (-7.1115)	0.637

注：括号内为 t 统计量；***、**、* 分别表示在 1%、5% 和 10% 的水平上显著。

对单资产时间序列回归结果的分析表明，所有行业的截距项 (α) 均不显著异于零，支持了 Fama-French 三因子模型对这些行业收益率的良好解释能力。市场因子 (β_{MKT}) 在所有行业均呈现显著的正系数，数值范围在 0.88 至 1.15 之间，表明这些行业对市场

普遍呈现较强敏感性。值得注意的是，银行行业的市场 β 系数最低（0.88），反映了该行业相对较低的系统性风险特征；而有色金属行业的市场 β 系数最高（1.15），说明其对市场波动的高度敏感性。

规模因子（ β_{SMB} ）在大多数行业显示出显著的正系数，银行业为明显例外，其 SMB 系数为显著负值（-0.25）。本差异揭示了银行板块与其他行业在规模特征上的本质区别：银行业主要由大市值股票构成，其收益率表现与小市值股票呈现负相关性；而其他行业，特别是电气设备（1.03）和化工（0.98）则呈现出与小市值股票更为相似的收益模式。

价值因子（ β_{HML} ）则呈现出更为复杂的行业异质性。银行业对 HML 因子表现出显著正向敏感性（0.29），表明其具有典型的价值型特征；而电气设备、化工和建筑材料行业对 HML 因子的敏感性则显著为负，分别为-0.54、-0.48 和-0.37，体现出这些行业的成长型特征。钢铁行业是唯一一个 HML 系数不显著的行业，表明其收益率与价值因子相对独立。

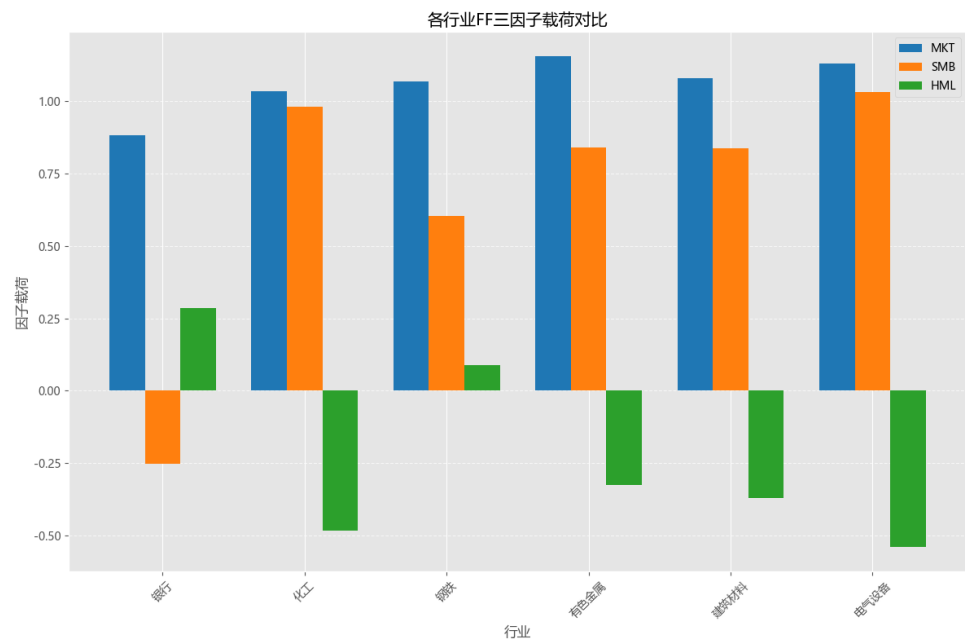


图 3-1 各行业 FF 三因子载荷对比

图 3-1直观展示了各行业对三个因子的敏感性差异，清晰呈现了行业间存在的风险暴露异质性。从市场风险角度看，所有行业均呈现出较高的系统性风险暴露；从规模效应看，除银行外，其他行业均表现出对小市值溢价的正向暴露；从价值维度看，行业间差异最为显著，形成了以银行为代表的价值型板块与以电气设备为代表的成长型板块的鲜明对比。

模型的整体解释力度方面，各行业的调整 R 方均在 0.63 至 0.72 之间，其中建筑材料行业的拟合优度最高（0.725），而电气设备行业最低（0.637）。这表明 FF 三因子模型能够解释这些行业超过 60% 的收益率波动，体现了该模型在中国市场中具有相当的解释力。图 3-2直观展示了各行业拟合优度的对比，所有行业的 R 方均在 0.63 以上，进一步证实了该模型在中国 A 股市场中解释行业超额收益时间序列变化的适用性。




图 3-2 各行业 FF 三因子模型的拟合优度对比

3.2 FF 三因子模型的多资产联合检验

为进一步验证 FF 三因子模型的有效性，本研究在单资产检验的基础上，采用 Gibbons-Ross-Shanken (GRS) 检验进行多资产联合检验。表 3.2展示了 GRS 联合检验的详细结果。

表 3.2 FF 三因子模型的 GRS 联合检验结果

检验项目	统计量	评价
GRS 统计量	1.3429	不能拒绝所有 $\alpha=0$ 的假设
p 值	0.2367	
5% 临界值	2.1252	
资产数量 (N)	6	样本充足
观测期数 (T)	459	
因子数量 (K)	3	
所有 α 的平均绝对值	0.0017	经济显著性低
所有 α 的平方和	0.0000126	整体偏离程度小

GRS 检验结果显示，统计量为 1.34，对应 p 值为 0.24，显著低于 5% 显著性水平下的临界值 2.13，因此无法拒绝“所有行业 α 值同时为零”的原假设。所有行业 α 值的平均绝对值仅为 0.0017，表明各行业收益率对三因子模型的偏离程度在经济上也不显著。这一结果进一步支持了 FF 三因子模型对中国股市行业收益差异的解释能力，表明三因子系统性风险已能充分解释样本期间内各行业的超额收益率。

进一步分析各行业在联合检验框架下的表现，我们发现尽管个别行业（如化工和钢

铁)的单资产检验中 α 的 t 值接近显著水平,但在考虑因子收益的时变特性和残差的横截面相关性后,整体检验无法拒绝模型的有效性。这种现象反映了单资产检验和多资产联合检验在统计功效上的差异,也突显了多资产联合框架在评估资产定价模型时的重要性。

多资产检验结果与单资产检验形成互补,共同表明 Fama-French 三因子模型在解释中国行业指数收益方面具有显著能力。市场、规模和价值三个系统性风险因素能够捕捉大部分行业收益的横截面和时间序列变化,上述发现为构建以行业为基础的投资组合和风险管理策略提供了理论依据。

值得一提的是,虽然三因子模型在解释行业指数层面表现良好,但正如后续分析将展示的,当考察个股层面的定价机制时,中国股市可能存在与经典理论预期不一致的现象,这反映了中国股市微观结构与成熟市场的差异性。

3.3 市值与盈利价格比的序贯排序分析

本研究采用序贯排序法分析了市值因素与盈利价格比(市盈率的倒数)对股票收益率的联合影响,通过构建二维排序投资组合,揭示中国 A 股市场在 2004 至 2023 年间的规模效应与价值效应。表 3.3展示了按市值和盈利价格比序贯排序后得到的 25 个投资组合的平均月收益率。

表 3.3 按市值和盈利价格比的序贯排序结果(月平均收益率)

市值分组	盈利价格比分组(从高到低)					市值组平均
	1(价值型)	2	3	4	5(成长型)	
1(小)	-0.0060	0.0018	0.0047	0.0070	0.0045	0.0024
2	-0.0016	0.0065	0.0080	0.0097	0.0154	0.0076
3	-0.0016	0.0069	0.0116	0.0134	0.0198	0.0100
4	0.0041	0.0073	0.0124	0.0164	0.0206	0.0122
5(大)	0.0069	0.0068	0.0168	0.0248	0.0213	0.0153
盈利价格比组平均	0.0004	0.0059	0.0107	0.0143	0.0163	0.0095

序贯排序结果揭示了中国股市存在显著的反向规模效应和反向价值效应。从市值维度看,平均月收益率随着市值增加而单调递增,从小市值组合的 0.24% 逐步上升至大市值组合的 1.53%。最大市值组合与最小市值组合之间 1.29% 的月度收益率差异(年化约 15.48%)明确表明中国股市存在显著的反向规模效应,即大市值股票系统性优于小市值股票,这与经典 Fama-French 模型中小市值股票获得风险溢价的发现形成鲜明对比。

图 3-3直观展示了不同市值和盈利价格比组合的月平均收益率分布,热力图清晰呈现了收益率随市值增加和盈利价格比降低而提高的趋势。从颜色变化可以明显观察到,右上角(大市值-低盈利价格比)区域的收益率明显高于左下角(小市值-高盈利价格比)




图 3-3 不同市值和盈利价格比分组的月平均收益率热力图（2004-2023 年）

区域，这一模式在整个样本期间保持一致，表明反向规模效应和反向价值效应是中国股市的稳健特征。

从价值维度考察，投资组合的平均月收益率随盈利价格比降低而增加，即从价值型向成长型转变时收益率呈上升趋势。最低盈利价格比组合（成长型）的月均收益率为 1.63%，显著高于最高盈利价格比组合（价值型）的 0.04%，两者差异达 1.60%（年化约 19.20%）。这表明中国股市存在系统性的反向价值效应，即成长型股票的表现优于价值型股票，同样与经典金融理论预期相反。

进一步分析投资组合间的交互效应，发现市值和盈利价格比因素之间存在复杂互动。以大市值-高盈利价格比（大盘价值）组合与小市值-低盈利价格比（小盘成长）组合为例，前者的月均收益率为 0.69%，显著高于后者的 0.45%，这进一步印证了在中国市场环境下大盘股的系统性优势。

最引人注目的是，大市值-次低盈利价格比组合（第 5 市值组-第 4 盈利价格比组）获得了所有 25 个组合中最高的月均收益率 2.48%，该现象表明市场对兼具一定成长性且规模较大的股票给予了特别青睐。这可能反映了机构投资者在中国市场中占据主导地位，而这些投资者倾向于配置流动性较好的大市值成长股。

综合来看，序贯排序分析的结果挑战了传统金融理论中的规模效应和价值效应假设，揭示了中国股市独特的定价机制，为投资策略设计与资产定价模型完善提供了重要

实证依据。

3.4 Fama-MacBeth 横截面回归分析

为深入检验市值、盈利价格比和 CAPM Beta 对股票收益率的解释能力，本研究采用 Fama-MacBeth 两阶段回归方法，分析了 2004 至 2023 年期间的中国 A 股横截面数据。表 3.4 报告了全样本期间及两个子样本期间的回归结果。

表 3.4 Fama-MacBeth 回归结果

	全样本期间 (2004-2023)	子期间 1 (2004-2013)	子期间 2 (2014-2023)
常数项	-0.2014*** (-6.33)	-0.1834*** (-4.50)	-0.2315*** (-4.53)
Beta	0.0165** (2.11)	0.0175* (1.72)	0.0149 (1.22)
对数流通市值	0.0096*** (6.87)	0.0090*** (4.93)	0.0106*** (4.89)
盈利价格比	-0.3733*** (-7.14)	-0.3717*** (-5.31)	-0.3760*** (-4.89)
平均 R^2	0.0676	0.0761	0.0533
观测月份数	192	120	72

注：括号内为 t 统计量；***、**、* 分别表示在 1%、5% 和 10% 的水平上显著。

Fama-MacBeth 回归结果强化并扩展了前述序贯排序分析的发现。在全样本期间（2004-2023 年），三个关键因素均呈现出统计显著的系数。Beta 系数为 0.0165（ $t=2.11$ ），表明系统性风险在中国股市定价中发挥着积极作用，符合 CAPM 理论预期的风险溢价存在。对数流通市值系数为显著正值 0.0096（ $t=6.87$ ），进一步证实了中国股市存在反向规模效应，即市值较大的股票在控制其他因素后仍能获得更高的预期收益。盈利价格比系数为显著负值 -0.3733（ $t=-7.14$ ），同样印证了市场存在反向价值效应，投资者更加青睐低盈利价格比（高市盈率）的成长型股票。

将全样本划分为两个子期间后，大多数结论保持稳健。对数流通市值和盈利价格比的系数在两个子期间均保持高度显著，且符号与全样本一致，表明这两种效应在中国股市中具有持续性。值得注意的是，Beta 系数的显著性随时间有所减弱，从第一子期间的边际显著（ $t=1.72$ ）降至第二子期间的不显著（ $t=1.22$ ），这可能反映了系统性风险在近期对股票定价的影响有所减弱。

图 3-4 展示了回归系数随时间的波动模式，包括 Beta 系数、对数流通市值系数和盈利价格比系数的月度变化。尽管三个系数的整体平均值分别为正、正和负，但它们的时

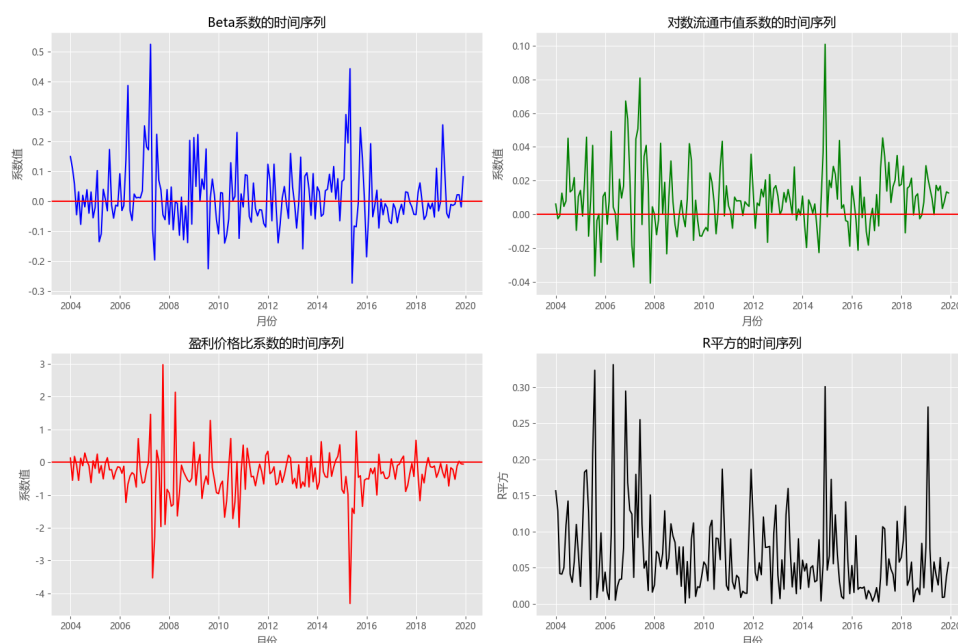


图 3-4 月度 Fama-MacBeth 回归系数的时间序列变化

间序列均表现出较大波动性，这说明风险因子溢价在不同市场环境下存在显著变化。特别是在 2008 年金融危机和 2015 年股灾等市场剧烈波动期间，系数波动尤为明显，表明在极端市场环境下，各因子对股票收益率的影响会发生显著变化。图中右下角还展示了 R 平方的时间序列变化，反映了模型解释力在不同月份间的差异。




图 3-5 不同时期各系数显著月份的比例 ($|t| > 1.96$)

图 3-5展示了各风险因子在不同时期内显著月份的比例。在整个研究期间，Beta、对数流通市值和盈利价格比的显著月份比例分别为 71%、69% 和 71%，表明这些因素在大多数月份中对股票收益率具有显著解释力。同时，我们注意到第一子期间（2004-2013 年）各因子的显著性与全样本期间基本一致，而第二子期间（2014-2023 年）Beta 因子

和对数流通市值因子的显著性略有下降，这可能反映了近期市场定价机制的变化。

回归的平均 R 方为 0.0676，表明模型整体解释了约 6.76% 的横截面收益率变异。尽管数值相对较低，但与资产定价实证研究中通常观察到的横截面 R 方相当，反映了股票收益的高度随机性与预测难度。值得注意的是，第一子期间（2004-2013 年）的平均 R 方（0.0761）显著高于第二子期间（2014-2023 年）的 0.0533，这可能表明近期市场效率的提高或其他未被模型捕捉的因素在近期发挥了更大作用。

总体而言，Fama-MacBeth 回归结果与序贯排序分析高度一致，共同表明中国股市存在显著的反向规模效应和反向价值效应，同时 CAPM 预测的系统性风险溢价也得到了一定程度的支持。这些发现对理解中国股市的定价机制、构建适合中国市场的资产定价模型以及制定有效的投资策略均具有重要启示。

中国股市呈现反向规模效应和反向价值效应的原因可能多方面的。从制度环境看，中国股市的 IPO 审核制度对小市值公司形成一定壁垒，上市公司普遍规模较大，弱化了小市值溢价；从投资者结构看，机构投资者占比逐年提高，其偏好流动性较好的大市值股票的倾向助推了大市值股票的表现；从行为金融角度看，中国投资者可能对成长性预期存在系统性乐观偏差，推高了高市盈率股票的估值水平和实现收益率。

4 讨论与结论

本研究通过对 Fama-French 三因子模型的多维度检验、序贯排序分析以及 Fama-MacBeth 回归分析，系统考察了中国 A 股市场在 2004 至 2023 年间的资产定价特征与风险因子结构。研究发现揭示了中国股市资产定价机制的独特性及其与经典金融理论预期的显著差异。

首先，基于行业指数的 FF 三因子模型检验表明，该模型在时间序列维度展示出良好的解释力。无论是单资产检验还是 GRS 联合检验，均未能拒绝“截距项为零”的假设，表明市场、规模和价值三个系统性风险因素已能充分解释中国行业指数的超额收益。行业间差异分析揭示了风险暴露的行业异质性：银行业呈现低市场风险、负规模敏感性和正价值敏感性，而电气设备、化工等行业则表现出高市场风险、正规模敏感性和负价值敏感性，形成了价值型与成长型行业的鲜明对比。行业层面的发现支持了三因子模型在解释中国市场行业收益差异方面的有效性。

然而，当考察个股层面的定价机制时，本研究发现了与经典理论预期相反的市场特征。序贯排序分析揭示了中国股市存在显著的反向规模效应和反向价值效应。大市值股票的平均月收益率系统性高于小市值股票，两者差异高达 1.29%（年化约 15.48%）；同时，低盈利价格比（高市盈率）的成长型股票表现显著优于高盈利价格比（低市盈率）的价值型股票，月度差异达 1.60%（年化约 19.20%）。最引人注目的是，大市值-次低盈利价格比组合获得了所有 25 个投资组合中最高的月均收益率（2.48%），表明市场特别青睐兼具一定成长性且规模较大的股票。

Fama-MacBeth 回归进一步证实了上述发现。在控制其他因素后，对数流通市值系

数显著为正 (0.0096, $t=6.87$), 盈利价格比系数显著为负 (-0.3733, $t=-7.14$), 二者在不同子期间均保持稳健。同时, Beta 系数整体上显著为正 (0.0165, $t=2.11$), 支持了 CAPM 预期的系统性风险溢价存在, 但其显著性在近期有所减弱。各因子在研究期间内约 70% 的月份中显著影响股票收益, 表明这些因素在解释横截面收益差异方面具有持久性。

中国股市呈现反向规模效应和反向价值效应的原因可能是多方面的。从制度环境看, 中国股市的 IPO 审核制度对小市值公司形成一定壁垒, 上市公司普遍规模较大, 弱化了小市值溢价; 从投资者结构看, 机构投资者占比逐年提高, 其偏好流动性较好的大市值股票的倾向助推了大市值股票的表现; 从行为金融角度看, 中国投资者可能对成长性预期存在系统性乐观偏差, 推高了高市盈率股票的估值水平和实现收益率。此外, 监管政策与交易制度的特殊性也可能影响因子溢价的形成机制。

研究结果对资产定价理论与投资实践均有重要启示。在理论层面, 传统基于美国市场构建的多因子模型可能不足以准确描述中国股市的风险-收益关系, 需要发展更适合中国国情的本土化资产定价模型; 在实践层面, 投资者在中国市场进行投资时不应机械套用小市值和价值投资策略, 而应考虑配置大市值成长型股票, 尤其是那些兼具规模优势和成长潜力的股票。

本研究也存在一些局限性。首先, 样本期间跨度较长, 市场环境和监管政策在此期间发生了显著变化, 可能影响结果的稳健性; 其次, 我们仅考虑了市值、盈利价格比和 Beta 三个主要因素, 未能纳入动量、流动性、波动率等其他可能影响股票收益的因素; 此外, 本研究的样本选择可能存在幸存者偏差, 因为只有在整个样本期间持续存在的股票才被纳入分析。

未来研究可在以下方向进一步深化: 一是拓展模型框架, 引入更多风险因子构建更全面的多因子模型; 二是细分样本期间, 分析不同市场状态下因子溢价的动态变化; 三是探索因子溢价形成的微观机制, 结合投资者行为、市场微观结构等视角深入解析中国股市的定价特征; 四是研究资产定价异象的经济意义, 分析反向规模效应和反向价值效应与中国宏观经济结构及政策环境的关联。通过这些努力, 有望构建更加完善的中国股市资产定价理论体系, 为投资者提供更为有效的决策依据。

参考文献

- [1] 张宏亮 赵雅娜. FF 三因子模型风险因子的有效性检验——基于 2001-2011 年我国资本市场数据. 财会通讯, 2014(30): 113-116.
- [2] 赵胜民, 闫红蕾, 张凯. Fama-French 五因子模型比三因子模型更胜一筹吗——来自中国 A 股市场的经验证据. 南开经济研究, 2016(2): 41-59.
- [3] 李志兵, 杨光益, 冯永昌. Fama-French 五因子模型在中国股票市场的实证检验. 金融研究, 2017(6): 191-206.

- [4] CARPENTER J N, LU F, WHITELOW R F. The real value of China' s stock market. Journal of Financial Economics, 2021, 139: 679-696.
- [5] LIU J, STAMBAUGH R F, YUAN Y. Size and value in China. Journal of Financial Economics, 2019, 134: 48-69.

5 附录

本研究的核心代码如下：

```

1 # ===== FF三因子模型的单资产时间序列检验 =====
2
3 # 估计三因子模型参数并检验是否满足FF三因子模型
4 def test_ff_model(industry_returns, factors):
5     all_results = {}
6     test_conclusions = {}
7
8     for industry_name, returns in industry_returns.items():
9         # 确保数据对齐
10        aligned_data = pd.concat([returns, factors], axis=1, join='inner').
            dropna()
11
12        # 计算超额收益率
13        excess_returns = aligned_data.iloc[:, 0] - aligned_data['RF']
14
15        # 准备自变量
16        X = aligned_data[['MKT', 'SMB', 'HML']]
17        X = sm.add_constant(X)
18
19        # 运行OLS回归
20        model = sm.OLS(excess_returns, X)
21        results = model.fit()
22
23        # 计算t统计量
24        t_stats = calculate_t_statistic(results)
25
26        # 模型检验：判断是否满足FF三因子模型
27        alpha = results.params['const']
28        alpha_pvalue = results.pvalues['const']
29        r_squared = results.rsquared
30        f_stat = results.fvalue

```

```

31     f_pvalue = results.f_pvalue
32
33     # 判断是否满足三因子模型
34     alpha_significant = alpha_pvalue < 0.05
35     model_significant = f_pvalue < 0.05
36
37     if not alpha_significant and model_significant:
38         conclusion = "满足FF三因子模型, a不显著, 模型整体显著"
39     elif alpha_significant and model_significant:
40         conclusion = "不完全满足FF三因子模型, a显著, 模型整体显著"
41     elif not alpha_significant and not model_significant:
42         conclusion = "不满足FF三因子模型, a不显著, 但模型整体不显著"
43     else:
44         conclusion = "不满足FF三因子模型, a显著, 模型整体不显著"
45
46     # 存储结果
47     all_results[industry_name] = t_stats
48     test_conclusions[industry_name] = {
49         'alpha': alpha, 'alpha_pvalue': alpha_pvalue,
50         'r_squared': r_squared, 'conclusion': conclusion,
51         # 其他统计信息...
52     }
53
54     return all_results, test_conclusions
55
56
57 # ===== FF三因子模型的多资产联合检验 =====
58
59 # 使用GRS检验进行多资产联合检验
60 def multi_asset_ff_test(industry_returns, factors):
61     # 1. 对每个行业单独进行OLS估计
62     all_results = {}
63     all_params = {}
64     all_residuals = {}
65
66     for industry, returns in industry_returns.items():
67         # 对齐数据并进行回归
68         aligned_data = pd.concat([returns, factors], axis=1, join='inner').
69             dropna()
69         excess_returns = aligned_data.iloc[:, 0] - aligned_data['RF']

```

```

70     X = sm.add_constant(aligned_data[['MKT', 'SMB', 'HML']])
71     model = sm.OLS(excess_returns, X)
72     results = model.fit()
73
74     # 存储结果
75     all_results[industry] = results
76     all_params[industry] = results.params
77     all_residuals[industry] = results.resid
78
79     # 2. 计算GRS统计量
80     # 提取所有行业的alpha值
81     alphas = np.array([params['const'] for params in all_params.values()])
82
83     # 计算残差的协方差矩阵
84     T = len(next(iter(all_residuals.values())))) # 样本数
85     residuals_df = pd.DataFrame(all_residuals)
86     Sigma = residuals_df.cov() # 残差协方差矩阵
87
88     # 计算GRS检验公式相关参数
89     N = len(all_results) # 资产数量
90     K = 3 # 三个因子
91     mu_k = np.array([factors['MKT'].mean(), factors['SMB'].mean(), factors['HML']
92                      '.mean()])
93     factor_data = factors[['MKT', 'SMB', 'HML']]
94     Omega = factor_data.cov()
95
96     # 计算GRS统计量
97     Omega_inv = np.linalg.inv(Omega)
98     mu_Omega_inv_mu = np.dot(np.dot(mu_k, Omega_inv), mu_k)
99     Sigma_inv = np.linalg.inv(Sigma)
100     alpha_Sigma_inv_alpha = np.dot(np.dot(alphas, Sigma_inv), alphas)
101     GRS_stat = ((T - N - K) / N) * (1 + mu_Omega_inv_mu)**(-1) *
102         alpha_Sigma_inv_alpha
103
104     # 计算p值 (F分布, 自由度为N和T-N-K)
105     p_value = 1 - stats.f.cdf(GRS_stat, N, T - N - K)
106
107     joint_test_result = {
108         'GRS_stat': GRS_stat, 'p_value': p_value,
109         'reject_H0': p_value < 0.05, 'N': N, 'T': T, 'K': K,

```

```

108     # 其他统计信息...
109 }
110
111 # 3. 整理单个资产检验结果
112 individual_results = {}
113 for industry, results in all_results.items():
114     individual_results[industry] = {
115         'alpha': results.params['const'],
116         'alpha_tstat': results.tvalues['const'],
117         'beta_mkt': results.params['MKT'],
118         'beta_smb': results.params['SMB'],
119         'beta_hml': results.params['HML'],
120         'r_squared': results.rsquared,
121         # 其他统计信息...
122     }
123
124 return joint_test_result, individual_results
125
126
127 # ===== 市值与盈利价格比的序贯排序分析 =====
128
129 # 序贯排序函数：先按市值排序，再按盈利价格比排序
130 def sequential_sort(df, date_col='日期_Date', return_col='月收益率_Monret',
131                    first_sort_col='流通市值', second_sort_col='盈利价格比',
132                    n_groups=5):
133     results = []
134     all_months = sorted(df[date_col].unique())
135
136     for date in all_months:
137         # 获取当月的数据
138         month_data = df[df[date_col] == date].copy()
139
140         # 确保数据足够
141         if len(month_data) < n_groups * 2:
142             continue
143
144         # 删除无效值和异常值
145         month_data = month_data.dropna(subset=[first_sort_col, second_sort_col,

```

```

        return_col] < 0.5)]
146 month_data = month_data[month_data[second_sort_col] > 0]
147
148 if len(month_data) < n_groups * 2:
149     continue
150
151 try:
152     # 先按流通市值排序分组（从小到大）
153     month_data['size_rank'] = pd.qcut(month_data[first_sort_col],
154                                       n_groups, labels=False, duplicates='drop')
155
156     # 在每个流通市值分组内，按盈利价格比排序再分组（从高到低）
157     for size_rank, size_group in month_data.groupby('size_rank'):
158         if len(size_group) < n_groups:
159             continue
160
161         # 负号使盈利价格比从高到低排序
162         size_group['ep_rank'] = pd.qcut(-size_group[second_sort_col],
163                                         n_groups, labels=False, duplicates='drop')
164
165         # 计算每个分组的平均收益率
166         for ep_rank, ep_group in size_group.groupby('ep_rank'):
167             avg_return = ep_group[return_col].mean()
168             results.append({
169                 '日期': date,
170                 '市值分组': size_rank + 1, # 从1开始
171                 '盈利价格比分组': ep_rank + 1, # 从1开始
172                 '平均收益率': avg_return,
173                 '股票数量': len(ep_group)
174             })
175
176 except Exception as e:
177     continue
178
179 results_df = pd.DataFrame(results)
180 return results_df
181
182 # 计算最终的各分组时间序列平均收益率
183 def calculate_final_results(sorted_results):
184     # 按市值和盈利价格比分组计算平均收益率
185     final_results = sorted_results.groupby(['市值分组', '盈利价格比分组'])['平均

```

```

    收益率'].mean().reset_index()

183
184 # 转换为宽格式表格
185 pivot_table = final_results.pivot(index='市值分组', columns='盈利价格比分组',
    values='平均收益率')
186
187 # 确保所有的分组都存在, 填充缺失值
188 all_size_groups = range(1, 6) # 1到5
189 all_ep_groups = range(1, 6) # 1到5
190 pivot_table = pivot_table.reindex(index=all_size_groups, columns=
    all_ep_groups)
191
192 # 添加边缘平均值
193 size_means = sorted_results.groupby('市值分组')['平均收益率'].mean()
194 ep_means = sorted_results.groupby('盈利价格比分组')['平均收益率'].mean()
195 overall_mean = sorted_results['平均收益率'].mean()
196
197 pivot_table['市值组平均'] = size_means
198
199 # 计算列平均值并添加到表格底部
200 ep_means_row = pd.Series(index=pivot_table.columns)
201 for col in all_ep_groups:
202     if col in pivot_table.columns:
203         ep_means_row[col] = pivot_table[col].mean()
204 ep_means_row['市值组平均'] = overall_mean
205
206 pivot_table.loc['盈利价格比组平均'] = ep_means_row
207
208 return pivot_table
209
210
211 # ===== Fama-MacBeth横截面回归分析 =====
212
213 # 计算股票Beta值
214 def calculate_beta(df, window=36):
215     # 计算每个月的市场平均收益率(等权)
216     market_returns = df.groupby('日期_Date')['月收益率_Monret'].mean().
        reset_index()
217     market_returns.columns = ['日期_Date', '市场收益率']
218

```

```

219 # 合并市场收益率到主数据框
220 df_merged = pd.merge(df, market_returns, on='日期_Date', how='left')
221
222 # 计算超额收益率
223 df_merged['超额收益率'] = df_merged['月收益率_Monret'] - df_merged['月无风险
    收益率_Monrfret']
224 df_merged['市场超额收益率'] = df_merged['市场收益率'] - df_merged['月无风险收
    益率_Monrfret']
225
226 # 为每只股票计算Beta值
227 beta_results = []
228
229 for stock in df_merged['股票代码_Stkcd'].unique():
230     stock_data = df_merged[df_merged['股票代码_Stkcd'] == stock].copy()
231     stock_data = stock_data.sort_values('日期_Date')
232
233     # 使用滚动窗口计算Beta
234     for j in range(window, len(stock_data) + 1):
235         window_data = stock_data.iloc[j-window:j]
236         current_date = window_data.iloc[-1]['日期_Date']
237
238         try:
239             # 执行回归计算Beta
240             X = sm.add_constant(window_data['市场超额收益率'])
241             y = window_data['超额收益率']
242             model = sm.OLS(y, X).fit()
243             beta = model.params['市场超额收益率']
244
245             # 限制Beta值在合理范围
246             if beta < -3 or beta > 3:
247                 beta = 1.0
248         except:
249             beta = 1.0
250
251     beta_results.append({
252         '股票代码_Stkcd': stock,
253         '日期_Date': current_date,
254         'Beta': beta
255     })
256

```

```

257 # 将结果转换为DataFrame并合并到原始数据
258 beta_df = pd.DataFrame(beta_results)
259 df_with_beta = pd.merge(df, beta_df, on=['股票代码_Stkcd', '日期_Date'], how
    = 'left')
260
261 # 填充缺失的Beta值
262 df_with_beta['Beta'] = df_with_beta['Beta'].fillna(1.0)
263
264 return df_with_beta
265
266 # Fama-MacBeth两阶段回归
267 def fama_macbeth_regression(df, start_date, end_date):
268     # 筛选时间范围内的数据
269     df = df[(df['日期_Date'] >= start_date) & (df['日期_Date'] <= end_date)].
        copy()
270
271     # 对所有变量进行缩尾处理（处理极端值）
272     for col in ['对数流通市值', '盈利价格比', 'Beta']:
273         df[col + '_winsorized'] = df.groupby('年月')[col].transform(
274             lambda x: x.clip(lower=x.quantile(0.01), upper=x.quantile(0.99))
275         )
276
277     # 获取所有唯一的月份
278     all_months = df['日期_Date'].dt.to_period('M').unique()
279     all_months = sorted(all_months)
280
281     # 用于存储每个月的横截面回归结果
282     monthly_results = []
283
284     # 对每个月执行横截面回归
285     for month in all_months:
286         month_str = str(month)
287         month_start = month_str + '-01'
288         month_end = pd.Period(month).asfreq('D', 'end').strftime('%Y-%m-%d')
289
290         # 获取当月数据
291         month_data = df[(df['日期_Date'] >= month_start) & (df['日期_Date'] <=
            month_end)].copy()
292
293         # 确保数据充足并删除缺失值

```



```

294     if len(month_data) < 30:
295         continue
296
297     month_data = month_data.dropna(subset=['月收益率_Monret', '对数流通市值
        _winsorized',
298                                     '盈利价格比_winsorized', '
        Beta_winsorized'])
299
300     if len(month_data) < 30:
301         continue
302
303     try:
304         # 准备回归数据
305         X = sm.add_constant(month_data[['Beta_winsorized', '对数流通市值
        _winsorized', '盈利价格比_winsorized']])
306         y = month_data['月收益率_Monret']
307
308         # 执行OLS回归
309         model = sm.OLS(y, X)
310         results = model.fit()
311
312         # 收集结果
313         monthly_results.append({
314             '月份': month_str,
315             '常数项': results.params['const'],
316             'Beta': results.params['Beta_winsorized'],
317             '对数流通市值': results.params['对数流通市值_winsorized'],
318             '盈利价格比': results.params['盈利价格比_winsorized'],
319             '常数项_t值': results.tvalues['const'],
320             'Beta_t值': results.tvalues['Beta_winsorized'],
321             '对数流通市值_t值': results.tvalues['对数流通市值_winsorized'],
322             '盈利价格比_t值': results.tvalues['盈利价格比_winsorized'],
323             'R平方': results.rsquared,
324             '样本数': len(month_data)
325         })
326     except Exception as e:
327         continue
328
329     # 将结果转换为DataFrame
330     fm_results = pd.DataFrame(monthly_results)

```

```

331
332 # 计算Fama-MacBeth第二阶段结果（时间序列平均值和t统计量）
333 coef_means = fm_results[['常数项', 'Beta', '对数流通市值', '盈利价格比']].
    mean()
334 coef_stds = fm_results[['常数项', 'Beta', '对数流通市值', '盈利价格比']].std
    ()
335 n_periods = len(fm_results)
336 coef_t_stats = coef_means / (coef_stds / np.sqrt(n_periods))
337
338 # 输出结果
339 print("\nFama-MacBeth回归结果（时间序列平均值）:")
340 for coef, mean_val, t_stat in zip(['常数项', 'Beta', '对数流通市值', '盈利价
    格比'],
341                                   coef_means, coef_t_stats):
342     print(f"{coef}: {mean_val:.6f} (t = {t_stat:.2f})")
343
344 print(f"平均R平方: {fm_results['R平方'].mean():.4f}")
345
346 return fm_results
347
348 # 按日期区间运行Fama-MacBeth回归并比较不同时期的结果
349 def run_fama_macbeth_with_subperiods(df, full_period, subperiods):
350     # 分割时间区间
351     full_start, full_end = full_period.split(':')
352
353     # 完整期间回归
354     full_results = fama_macbeth_regression(df, start_date=full_start, end_date=
        full_end)
355
356     # 子期间回归
357     subperiod_results = []
358     for period in subperiods:
359         start_date, end_date = period.split(':')
360         sub_results = fama_macbeth_regression(df, start_date=start_date,
            end_date=end_date)
361         subperiod_results.append(sub_results)
362
363     return full_results, subperiod_results

```